

КОНЦЕПЦИЯ МОДЕЛИ НЕЙРОННОЙ СЕТИ ДЛЯ ДЕТЕКЦИИ ОБЪЕКТОВ НА ИЗОБРАЖЕНИИ

В. Ю. Паластрова – студентка 2 курса ПИм – 2;

А. Ю. Беляков – научный руководитель, кандидат технических наук, доцент,
ФГБОУ ВО Пермский ГАТУ, г. Пермь, Россия

Аннотация. В статье поднимается проблема контроля состояния конвейерной ленты, осуществляемый традиционными методами. Обсуждается современное решение и проблемы, которые могут повлиять на качество предлагаемого решения. В связи с этим рассмотрены и возможные методы по снижению данного влияния. Приведен концепция решения и методики работы с изображениями и моделью нейронной сети.

Ключевые слова. Алгоритм машинного зрения, дефектоскоп, технологии искусственного интеллекта. сверточные нейронные сети, метод контроля состояния конвейерной ленты.

Введение

Автор статьи ««Глаза» ИИ: что видят системы компьютерного зрения сегодня и что разглядят завтра?» от 2020 года акцентирует внимание на возможности применения компьютерного зрения во многих отраслях обыденной жизни. Отмечается обсуждение создания новых математических методов в научных кругах с целью создания искусственного интеллекта с безграничными возможностями [2].

Спустя 3 года наблюдается повсеместное применение технологий компьютерного зрения. Алгоритмы машинного зрения позволяют решать ряд серьезных задач на производстве, например такие, как классификация алмазов по цвету и форме на основе алгоритмов машинного обучения и компьютерного зрения, измерение качества и скорости флотации, контроль опасных зон и наличие СИЗов, контроль погрузочно – разгрузочных работ [3]. Так же, системы машинного зрения активно применяются в легкой и металлургической промышленности, для проверки качества маркировки, для выявления дефектов по всей линии

производства, для проверки печатных плат, для контроля внешнего вида неметаллических трубчатых изделий, в работе с биологическими объектами [5].

Однако в промышленном секторе, на текущий момент, применяется традиционный метод контроля состояния конвейерной ленты – визуальный. Такой подход требует максимальной внимательности и большое количество времени, так как осмотр необходимо выполнять перед утренней и вечерней сменой. Дополнительными недостатками являются протяженность ленты (от 1 км.) и расположение конвейера (в цехе или под землей). Существенным недостатком является и то, что метод позволяет определить состояние резинотканевой ленты лишь относительно качественных критериев оценки.

Количественные критерии оценки состояния возможно определить лишь при использовании инструментальных методов контроля с применением дефектоскопов. Существует несколько вариантов дефектоскопов, которые фиксируют состояние ленты с применением различных технологий, однако все они обладают теми или иными недостатками, ключевыми из которых являются большая масса и устаревший способ регистрации информации [1]. Таким образом, традиционные решения все быстрее морально устаревают, теряя свою востребованность и эффективность.

Следовательно, можно сделать вывод об отсутствии простого, быстрого и надежного способа контролировать повреждения в режиме реального времени, что влечёт за собой колоссальные траты и аварийные ситуации, которые влияют на безопасность производственного и эксплуатационного процессов.

В качестве современного решения можно предложить разработку технологического решения с применением машинного зрения, позволяющего контролировать состояние резинотканевой ленты в режиме реального времени, не требуя специализированного, дорогостоящего оборудования и аттестованного специалиста, что позволит снизить затраты на обслуживание.

Данное решение позволит предприятию перейти от традиционных методов контроля состояния конвейерной ленты к более современному и масштабируемому. Внедрение решения приведет к снижению затрат на техническое обслуживание и ремонт оборудования, предупреждая о появлении дефекта, что позволит предприятию быть более конкурентноспособным, исключить влияние человеческого фактора и аварийные ситуации.

Постановка проблемы

Технологии искусственного интеллекта становятся все более востребованы в промышленном секторе, а именно технологии видеоаналитики. Однако качественное обучение и дообучение модели требует большого набора данных, доступ к которому может быть ограничен по ряду внешних факторов. Например, Татьяна Воронова в статье «Глаза» ИИ: что видят системы компьютерного зрения сегодня и что разглядят завтра?» рассуждает над данным вопросом следующим образом: «Несмотря на то, что за годы существования Интернета накопилось гигантское множество примеров изображений, имеются специфические объекты, используемые только, например, в конкретном производстве, скажем, специальные инструменты, оборудование или знаки. Датасет для таких данных необходимо постоянно расширять по новому видеоматериалу, например, на основе данных, поступающих с камер заказчика, и регулярно дообучать систему.» [2]. В этой же статье приводится пример решения складывающейся проблемы путем изменения параметров модели или же использования нескольких архитектур.

Существует два типа параметров модели нейронной сети. Первый тип параметров – параметры, которые изменяет сама модель в процессе обучения. Второй тип параметров – гиперпараметры, которые задаются до момента начала обучения сети (количество обучающих итераций (Epoch), размер фильтра, ядра, количество нейронов на каждом слое).

Для глубокого обучения модели требуется несколько наборов данных.

Обучающий набор данных, который поступает на вход модели. Модель соответствующим образом корректирует обучающие параметры (веса и смещения) и выдает некий ответ.

Тестовый набор данных содержит в себе экземпляры объектов, близких к реальным данным, на которых модель будет запущена. Данный набор позволяет проверить точность обучения модели.

Для повышения точности срабатывания нейронной сети используют два способа: изменение архитектуры нейронной сети, в ходе которой меняется количество и структура ее слоев, или изменение гиперпараметров. Для определения начала переобучения модели используется *валидационный набор данных*.

Валидационный набор данных позволяет подобрать оптимальные значения гиперпараметров, например количество обучающих итераций (Epoch), и повысить точность работы на тестовом наборе данных.

При недостаточном объеме набора данных может возникнуть проблема переобучения модели: после нескольких итераций обучения модели, она начнет переобучаться и покажет результат работы 100% точности на обучающем наборе данных. Однако на тестовом наборе данных такая покажет некорректные результаты.

Проблема переобучения модели решается пополнением набора данных качественными обучающими данными, что не во всех случаях является возможным. Тогда прибегают к генерации новых данных на основе имеющихся, то есть к расширению данных. Процесс выглядит следующим образом, исходные данные преобразуются с помощью каких – либо трансформаций – поворот, увеличение, смещение пикселей, уменьшение и так далее (рис. 1).

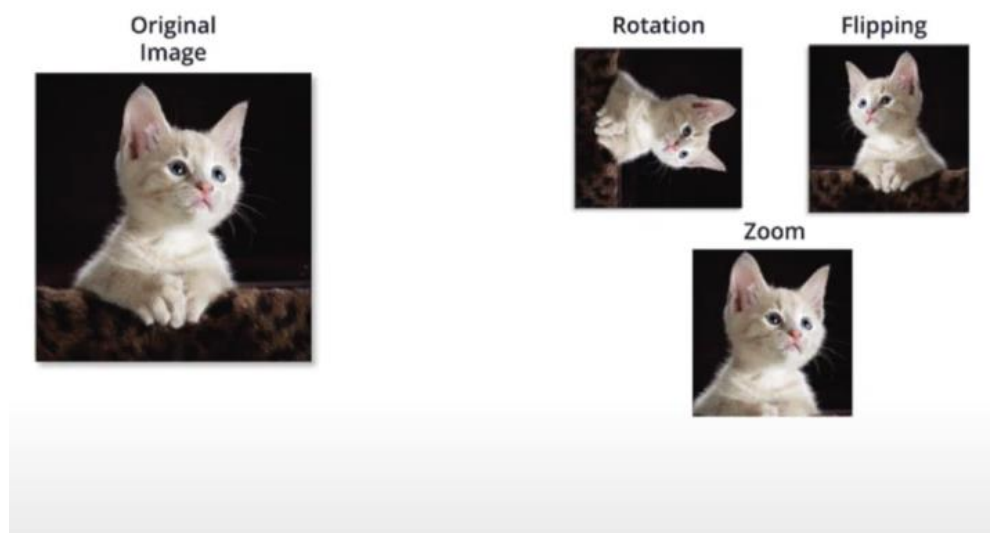


Рисунок 1 – Расширение данных

Использование расширения данных позволяет предотвратить переобучения модели и увеличить результирующую точность работы на тестовом наборе данных.

Использование методики Dropout также позволит избежать переобучения модели. Методика Dropout – исключение нейронов произвольным образом произвольных нейронов сети с каждой обучающей итерацией. Данная методика позволяет нейронной сети стать стабильнее и перераспределить значение ценности каждого нейрона таким образом, чтобы в случае отключения одного или нескольких нейронов это не влияло на точность работы. Под отключением нейронов подразумевается его исключение из процесса обучения и корректировка весов и смещения в процессе обратного распространения.

Описание концепции

Для распознавания дефектов подойдет специальная архитектура искусственных нейронных сетей, используемая для анализа и распознавания образов – сверточная нейронная сеть.

Сверточные нейронные сети (CNN) являются типом нейронных сетей, которые основаны на сверточной архитектуре и используются для обработки изображений, видео и других данных с двумерной структурой. Ключевой особенностью CNN является использование сверточных слоёв для сжатия информации и извлечения признаков, а затем использование полносвязных слоёв для классификации или регрессии [4].

Сверточные нейронные сети состоят из трёх основных типов слоев: сверточных, макс-пулинга и полносвязных (рис. 2).

Сверточные слои используют фильтры для извлечения признаков из изображения. Эти фильтры проходят по изображению и вычисляют значения для каждой локации, создавая новое изображение с меньшим количеством каналов и размером, что помогает сжимать информацию и извлекать важные признаки, такие как контуры и текстуры.

Слои макс-пулинга используются для уменьшения размерности изображения и устранения незначительных деталей. Они проходят по изображению и выбирают максимальное значение из каждой локации, создавая новое изображение с меньшим размером.

Полносвязные слои используются для классификации или регрессии. Они преобразуют информацию из предыдущих слоёв в выходные значения.




Рисунок 2 – Архитектура CNN

Сверточные нейронные сети эффективно извлекают признаки из изображений и других двумерных данных. Данное преимущество делает их очень полезными для множества задач компьютерного зрения, например, таких как классификация изображений, детекция объектов, сегментация изображений. По этой же причине они используются в других областях, таких как аудио и видео анализ, медицинское обслуживание и работа с естественным языком.

Сверточные нейронные сети играют важную роль и в развитии глубокого обучения, они были использованы во многих состязаниях с компьютерным зрением, где достигли отличных результатов. Они широко используются в промышленности, где применяются для автоматизации задач, таких как мониторинг качества и инспекция объектов [4].

Вывод

В рамках исследования был разработан прототип модели нейронной сети, иллюстрирующий, по какому принципу работает система на других данных. Точность обучения на обучающих данных достигла 90%, на валидационном наборе – 85%. Повысить вероятность возможно за счет изменения некоторых параметров модели.

Возможно, еще не все инструменты рассмотрены, которые понадобятся при разработке системы, однако в данный момент все внимание сконцентрировано на разработке и обучении нейронной сети.

Для разработки технологического решения подобраны: архитектура, стек технологий и инструменты, позволяющие оценить эффективность обучения и корректность получаемых результатов.

Существует вероятность, что при моделировании информационной системы не были учтены многие моменты, поэтому при дальнейшей разработке модели могут претерпеть изменения.

Список литературы

1. Атакулов, Л. Н. Обзор и анализ диагностики определения дефектов конвейерной ленты / Л. Н. Атакулов, Н. О. Полвонов, У. Э. Каюмов // Universum: технические науки. – 2022. – № 2. – С. 1–10. – URL: <https://7universum.com/ru/tech/archive/item/13045> (дата обращения: 28.11.2023).

2. «Глаза» ИИ: что видят системы компьютерного зрения сегодня и что разглядят завтра? // tadviser.ru : сайт, 2020. – URL:

https://www.tadviser.ru/index.php/Статья:Глаза_ИИ: что видят системы компьютерного зрения сегодня и что разглядят завтра (дата обращения: 28.11.2023).

3. Как используют Machine Learning и Computer Vision в добывающей промышленности // SE7EN.ws : сайт, 2020. – URL: <https://se7en.ws/machine-learning-i-computer-vision-na-obogatitelnykh-fabrikakh/> (дата обращения: 28.11.2023).

4. Нейронные сети: архитектура и обучение // pings.ru : сайт, 2022. – URL: <https://pings.ru/news/neironnye-seti-arxitektura-i-obuchenie/> (дата обращения: 28.11.2023).

5. Ситников, В. В. Обзор методов распознавания объектов, используемых в системах машинного зрения / В. В. Ситников, В. В. Люминарский, А. В. Коробейников // Вестник ИжГТУ имени М. Т. Калашникова. – 2018. – Т. 21, № 4. – С. 222–229.